

# BEV

## — .why bev perception

1. self-driving is a 3D/BEV perception problem
2. 2D to 3D直接人为用2D检测投影到3D，由于较远处像素信息较少，噪声较多，容易失真。

## Why BEV Perception?



1. Self-driving is a 3D/BEV perception problem
2. Unprojection from 2D to 3D is inherently challenging



3. make it easy for sensor fusion(多模态融合)

## 二 .LSS

**将单视图的检测扩展到多视图为什么不可行：**具体来说，针对来自n个相机的图像数据，我们使用一个单视图检测器，针对每个相机的每张图像数据进行检测，然后将检测结果根据对应相机的内外参数，转换到车辆本体参考下，这样就完成了多视图的检测。

这样简单的后处理无法data-driving，因为上面的转换是单向的，也就是说，我们无法反向区分不同特征的坐标系来源，因此我们无法轻易的使用一个端到端的模式来训练改善我们的自动感知系统

## Method

### 1. Lift: Latent Depth Distribution：将2D图像特征生成3D特征

对于每个像素，生成一系列离散的深度值（alpha，alpha为D\*1矩阵），在模型训练的时候，由网络自己选择合适的深度。

为什么要对每个像素定义一系列离散的深度值？因为2D图像中的每个像素点可以理解成一条世界中某点到相机中心的一条射线，现在不知道的是该像素具体在射线上位置(也就是不知道该像素的深度值)。本文是在距离相机5m到45m的视锥内，每隔1m有一个模型可选的深度值(这样每个像素有41个可选的离散深度值)

然后将alpha与feature c做外积，得到一个D\*C的矩阵，作为per-pixel outer product，下面这个图，由于第三个深度下特征最为显著，因此该位置的深度值为第三个

经过此操作，则估计出了pixel对应的depth信息，将2D图像特征生成3D特征




Fig. 3: We visualize the “lift” step of our model. For each pixel, we predict a categorical distribution over depth  $\alpha \in \Delta^{D-1}$  (left) and a context vector  $\mathbf{c} \in \mathbb{R}^C$  (top left). Features at each point along the ray are determined by the outer product of  $\alpha$  and  $\mathbf{c}$  (right).

## 2. Splat: Pillar Pooling: 将3D特征通过相机内外参，投影到一个统一的坐标系中

将多个相机中的像素点投影在同一张俯视图中，先过滤掉感兴趣域(以车身为中心200\*200范围)外的点。然后需要注意的是，在俯视图中同一个坐标可能存在多个特征，这里有两个原因:1是单张2D图像不同的像素点可能投影在俯视图中的同一个位置,2是不同相机图像中的不同像素点投影在俯视图中的同一个位置，例如不同相机画面中的同一个目标。对于同一个位置的多个特征，作者使用了sum-pooling的方法计算新的特征，最后得到了200x200xC的feature

最后接一个BevEncode的模块将200x200xC的特征生成200x200x1的特征用于loss的计算

## Conclusion


纯视觉bev检测的难点主要在于单目深度估计困难，本文提供了一种解决方法，但是由于对每一个pixel生成D\*C的feature，导致计算量较大。

## 三 .HMapNet

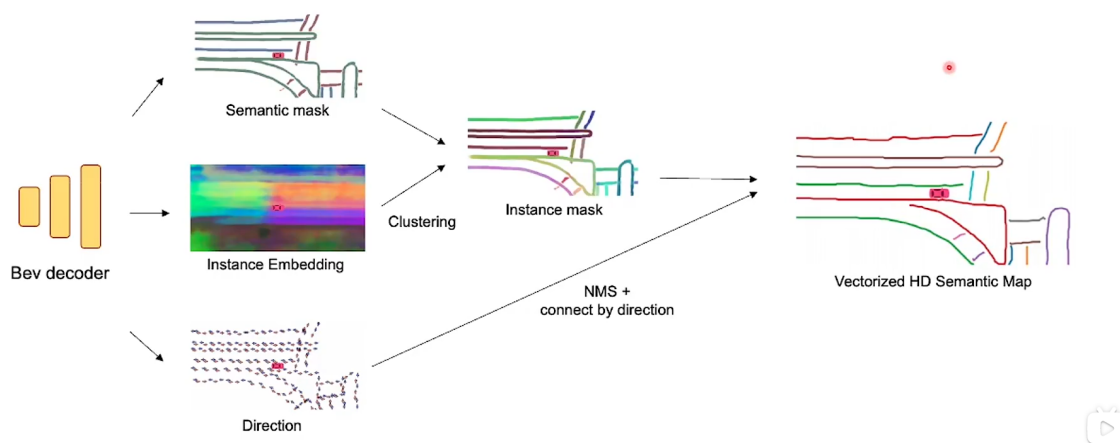

赵行老师视频中提到，但我并未细看，后续可能完善

### Model Architecture

1. Cam-view encoder
2. View transformation: implicit with NN
3. View projection: explicit with camera configurations
4. BEV decoder



## Vectorization



## 四 .DETR

首先回顾一下attention机制，attention可以看作是value的加权和，而value的权重是由对应的key与query的相似度决定的。

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

使用transformer，取代了现在模型需要手工设计的部分，例如NMS和anchor generation，真正做到了END TO END




Fig. 1: DETR directly predicts (in parallel) the final set of detections by combining a common CNN with a transformer architecture. During training, bipartite matching uniquely assigns predictions with ground truth boxes. Prediction with no match should yield a “no object” ( $\emptyset$ ) class prediction.

## Object detection set prediction loss

DETR最后输出N个box，N为固定值，本文设定N=100，再将N个框与gt做二分图匹配，从而得到真实的预测框，再算loss，舍弃了NMS，做到了postprocessing-free

二分图匹配问题采用匈牙利算法解算，cost matrix中填入 $L_{\text{match}}$

the predicted box as  $\hat{b}_{\sigma(i)}$ . With these notations we define  $\mathcal{L}_{\text{match}}(y_i, \hat{y}_{\sigma(i)})$  as  $-\mathbb{1}_{\{c_i \neq \emptyset\}} \hat{p}_{\sigma(i)}(c_i) + \mathbb{1}_{\{c_i \neq \emptyset\}} \mathcal{L}_{\text{box}}(b_i, \hat{b}_{\sigma(i)})$ .

# DETR architecture


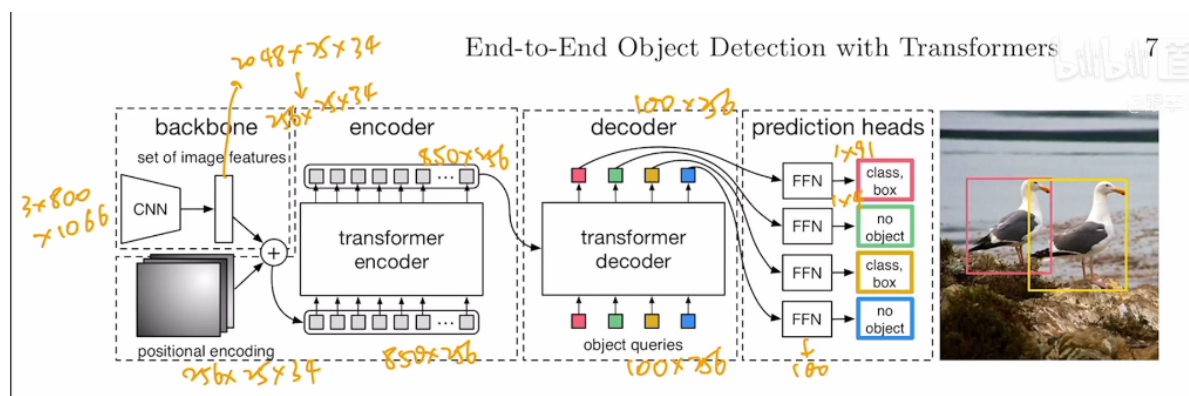


Fig. 2: DETR uses a conventional CNN backbone to learn a 2D representation of an input image. The model flattens it and supplements it with a positional encoding before passing it into a transformer encoder. A transformer decoder then takes as input a small fixed number of learned positional embeddings, which we call *object queries*, and additionally attends to the encoder output. We pass each output embedding of the decoder to a shared feed forward network (FFN) that predicts either a detection (class and bounding box) or a “no object” class.



## 1. CNN+positional encoding

先用cnn提取图像特征，因为要送入transformer中，需要位置编码，所以进行positional encoding

## 2. encoder

类似vit

## 3. decoder

加入了object queries，此为一个learnable positional embedding，decoder的输入是object queries ( $100 \times 256$ ，分别对应之前的256和最后输出的100个框)，另一个输入是encoder的输出；最后得到一个 $100 \times 256$ 的输出，本质上是一个cross-attention

## 4. prediction heads

FFN: feed forward network，就是一些mlp层，输出最终特征，供后续做二分图匹配和算loss

# 五 .Deformable DETR

DETR的缺点：训练困难，较难收敛；小目标检测效果不理想；参数量较大

造成以上缺点的原因可能是：在初始化时，attention模块对特征图中的所有像素点施加几乎一致的注意权值，所以需要较多epoch的训练来将注意力focus到稀疏的有意义的区域。

Deformable DETR结合了Deformable convolution(可变形卷积)的优秀的稀疏空间采样能力和transformer的关系建模能力

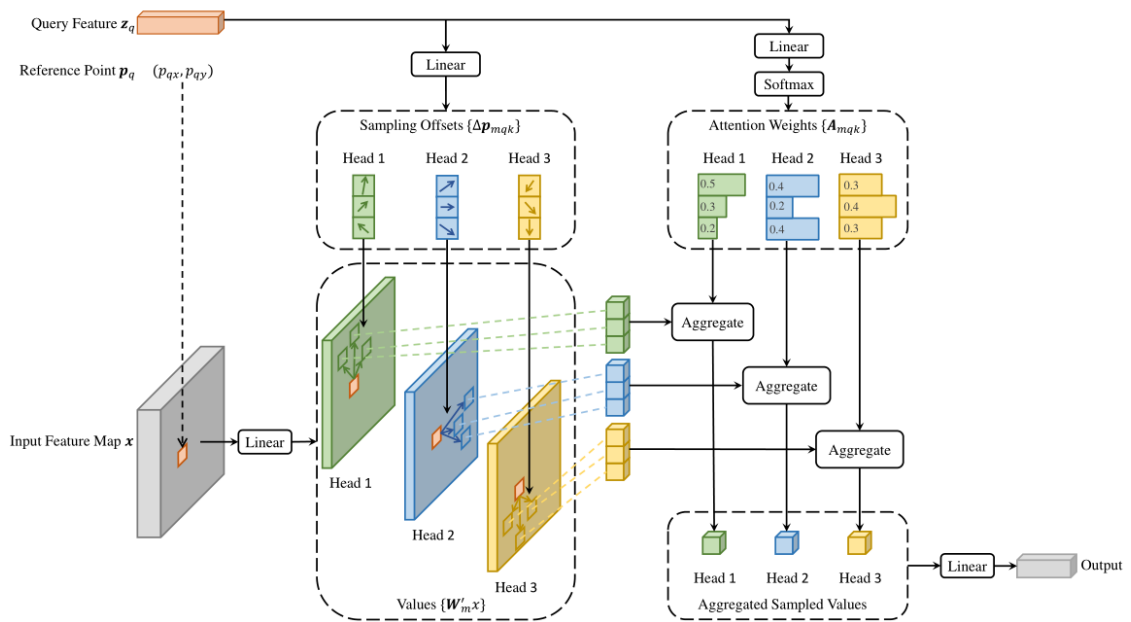


Figure 2: Illustration of the proposed deformable attention module.

## Deformable Convolution (可变形卷积)

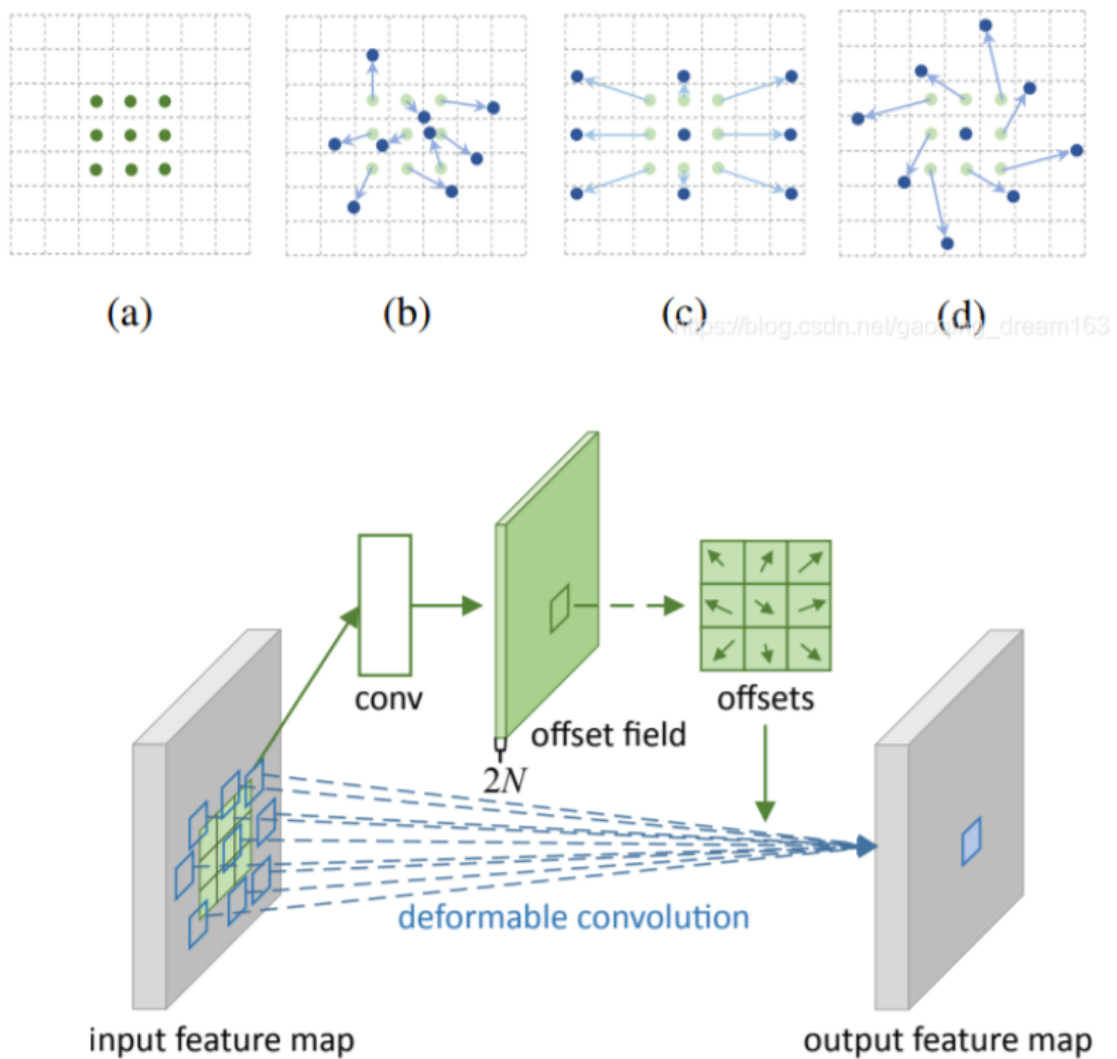


Figure 2: Illustration of  $3 \times 3$  deformable convolution.



offset是一个learnable的参数，可根据图像内容发生自适应的变化，从而适应不同物体的形状、大小等几何形变，可以高效的处理稀疏空间。

## Deformable Attention Module

将transformer运用到cv中一个很大的问题就是他的query会与所有key相关（key对应空间位置，一些空间位置可能不与该query相关），导致计算量很大，Deformable Attention Module将只关注参考点周围的一小部分key采样点，为每个query分配少量固定数量的key

先回顾一下基本的**multihead attention**计算方法

$$\text{MultiHeadAttn}(z_q, x) = \sum_{m=1}^M W_m \left[ \sum_{k \in \Omega_k} A_{mqk} \cdot W'_m x_k \right],$$

其中， $z_q$ 看作query，由 $x$ 经过线性变换生成， $q$ 是对应的索引， $k$ 是key的索引， $\Omega_k$ 即所有的 $k$ 集合， $m$ 代表是第几个注意力头部， $W_m$ 是对注意力施加在value后的结果进行线性变换从而得到不同头部的输出结果， $W'_m$ 用于将 $x_k$ 变换成value， $A_{mqk}$ 代表归一化的注意力权重。即所有的query都要与所有位置的key计算注意力权重，并且对应施加在所有的value上

**Deformable Attention:**

$$\text{DeformAttn}(z_q, p_q, x) = \sum_{m=1}^M W_m \left[ \sum_{k=1}^K A_{mqk} \cdot W'_m x(p_q + \Delta p_{mqk}) \right],$$

比multihead attention多了 $p_q$ 和 $\Delta p_{mqk}$ ， $p_q$ 可理解为代表 $z_q$ 的位置（理解成坐标即可），是2d向量，作者称其为reference points，而 $\Delta p_{mqk}$ 是实际采样点相对于参考点的offset，是一个learnable的参数。

实际操作过程中， $\Delta p_{mqk}$ 和注意力权重都由query经过一个3MK channel的全连接层算出，前2MK个channel计算 $\Delta p_{mqk}$ ，最后MK个channel经过softmax作为 $A_{mqk}$ ，即注意力权重。此处与传统transformer不同，注意力权重不是通过query和key的相关性计算的！

## Multi-scale Deformable Attention Module

$$\text{MSDeformAttn}(z_q, \hat{p}_q, \{x^l\}_{l=1}^L) = \sum_{m=1}^M W_m \left[ \sum_{l=1}^L \sum_{k=1}^K A_{mlqk} \cdot W'_m x^l(\phi_l(\hat{p}_q) + \Delta p_{mlqk}) \right], \quad (3)$$

将可变形注意力模块运用到多尺度上，每个query在每个特征层都会采样K个点，共有L层特征，从而在每个头部内共采样LK个点，注意力权重也是在这LK个点之间进行归一化，因为cross-attention以及可以建立不同特征层之间的关系，所以不用FPN结构。

## Deformable Transformer Encoder & Decoder

### Encoder

主要是用Deformable Attention替换了DETR中Encoder中的self-attention，由之前的对于一个query，每一层采集K个点作为keys，转换成，对一个query，所有层均采K个点作为keys

### Decoder

## 六 .DETR3D

---

首先是介绍了一种伪激光雷达的3D物体检测方案，即对一张2D的图片进行深度的预测，得到一个类似于激光雷达的点云图，运用一些点云的检测方法进行3D检测，此方法为two-stage：深度预测+3D检测，深度预测带来的误差影响后面